

شناسایی آماری الگو

تمرین های سری دو

فرهاد دلیرانی

۹۶۱۳۱۱۲۵

dalirani@aut.ac.ir

dalirani.1373@gmail.com

ساختار درختی پوشه‌ی ارسال شده:

report.pdf

[./computerProject:](#)

computerProject.py

[./problem1:](#)

problem1.py

[./problem2:](#)

problem2.py

[./problem3:](#)

problem3.py

[./problem4:](#)

problem4.py

[./problem5:](#)

problem5.py

[./problem6:](#)

problem6.py

[./problem7:](#)

problem7.py

تمام کدها با پایتون 3.6 نوشته شده‌اند.

همچنین از پکیج‌های زیر استفاده کرده‌ام:

numpy -

matplotlib -

البته برای راحتی در نصب پایتون 3.6 و پکیج‌های مربوط به دیتاساینس که numpy و matplotlib هم جزیی از آن پکیج‌ها هستند از Anaconda 5.0.0 استفاده کرده‌ام که همه‌ی موارد گفته شده را بدون دردسر و سختی نصب می‌کند. تنها کافی است آن را از <https://www.anaconda.com/download> دانلود کنید و Installer باقی کار را انجام می‌دهد.

زبان برنامه نویسی: پایتون 3.6

پکیج‌ها: پکیج‌های گفته شده را برای راحتی در نصب با Anaconda نصب کردم.

ورژن Anaconda من: Anaconda 5.0.0 For Linux Installer که البته همین ورژن برای سایر

سیستم عامل‌ها هم موجود است.

محیط برنامه نویسی: pyCharm Community Edition

سیستم عامل: Linux/Gnome Fedora – البته همان طور که خودتان اطلاع دارید سیستم عامل مهم نیست، برای آرایه‌ی اطلاعات بیشتر به سیستم عامل اشاره کردم. همین طور کدهایم را در ویندوز تست کردم و مشکلی نداشتند.

سوال ۱:

در ابتدا کدها و توضیحات 4 بخش a,b,c و d این سوال را توضیح می‌دهم و در آخر سوال، نتایج و خروجی‌های هر چهار بخش را باهم ارزیابی می‌کنم.

بخش a)

این بخش از سوال خواسته است $p(x|w_1)$ و $p(x|w_2)$ را رسم کنیم برای این منظور کد کامنت‌گذاری شده زیر را نوشته ام که دو تابع داده شده را رسم می‌کند:

```

1 #####
2 # Problem 1
3 #####
4
5 import matplotlib.pyplot as plt
6 import numpy as np
7
8
9 #  $p(x|w1)$  and  $p(x|w2)$ :
10 # densities
11 def xw1(x):
12     if x >= 0 and x <= 1:
13         return 2*x
14     else:
15         return 0
16
17
18 def xw2(x):
19     if x >= 0 and x <= 1:
20         return 2-2*x
21     else:
22         return 0
23
24
25 densities = [xw1, xw2]
26
27 #####
28 # Problem 1- a
29 #####
30 # Generate 200 point for drawing curves between (-1,2)
31 x = np.linspace(-1,2,num=200)
32
33 # Plot both densities
34 plt.plot(x, list(map(densities[0], x)), label='P(x|w1)', linestyle='-')
35 plt.plot(x, list(map(densities[1], x)), label='P(x|w2)', linestyle='-')

```

بخش (b)

این بخش خواسته است مرز تصمیم را برای زمانی که $P(w1) = P(w2) = 0.5$ است را پیدا کنیم. به همین خاطر ابتدا تابع زیر را نوشته ام که بر اساس رابطه‌ی زیر

$$p(x|w1)*P(w1) - p(x|w2)*P(w2) = 0$$

$$p(x|w1) = 2x \text{ in } (0,1)$$

$$p(x|w2) = 2-2x \text{ in } (0,1)$$

$$x_0 = P(w2)/(P(w1)+P(w2))$$

مقدار $x_0 = b$ که همان مرز تصمیم است را پیدا می‌کند:

```

39 # Problem 1- b
40 #####
41 # By finding x according to P(w1) and P(w2) from below equation:
42 #  $p(x|w1)*P(w1) - p(x|w2)*P(w2) = 0$ 
43 # we can easily find decision boundary.
44 # when  $p(x|w1)$  is  $2x$  in  $(0,1)$  and
45 #  $p(x|w2)$  is  $2-2x$  in  $(0,1)$  then
46 # decision boundary is  $x = P(w2)/(P(w1)+P(w2))$ 
47 def calculate_decision_boundary(pw1, pw2):|
48     """
49     This function finds decision boundary of  $p(x|w1) = 2x$  in  $(0,1)$  and
50      $p(x|w2) = 2-2x$  in  $(0,1)$ 
51     :param pw1: prior  $P(w1)$ 
52     :param pw2: prior  $P(w2)$ 
53     :return: return a number which indicate
54             decision boundary( $x = P(w2)/(P(w1)+P(w2))$ )
55     """
56     return pw2/(pw1 + pw2)

```

و در ادامه تابع بالا را فراخوانده‌ام و آن را رسم کرده‌ام:

```

59 # Generate 200 point for drawing decision boundary (-0.5,2.5)
60 y = np.linspace(-0.5, 2.5, num=200)
61
62 # Plot decision boundary when P(w1) = P(w2) = 0.5
63 plt.plot([calculate_decision_boundary(pw1=.5, pw2=0.5)]*200, y,
64          label='Decision Boundary when P(w1)={},P(w2)={}'.format(0.5, 0.5)
65          , linestyle='--')
66

```

بخش c)

این بخش خواسته است خطای classifier را حساب کنیم. که برابر می شود با مجموع مساحت دو مثلث سمت چپ و راست مرز تصمیم ضرب در prior هایشان که برای محاسبه ی آن تابع زیر را بر اساس روابط زیر نوشته ام:

$$p(x|w1) = 2x \text{ in } (0,1)$$

$$p(x|w2) = 2-2x \text{ in } (0,1)$$

$x0$ is decision boundary

$$\text{Error} = (P(w1)*(x0 * (2*x0)) / 2) + (P(w2) * ((1-x0) * (2-2*x0)) / 2)$$

برای محاسبه ی خطا کد زیر را نوشته ام که شامل تابع محاسبه ی خطا و فراخوانی آن برای محاسبه ی خطا است:


```
#####
# Problem 1- c
#####
def error_of_classifier(pw1, pw2, x0):
    """
    This function finds errors of classifier when
     $p(x|w1) = 2x$  in  $(0,1)$  and
     $p(x|w2) = 2-2x$  in  $(0,1)$ 
    :param pw1: prior  $P(w1)$ 
    :param pw2: prior  $P(w2)$ 
    :param x0:  $x0$  is decision boundary
    :return: return a number which indicate
            error of classifier
    """
    return (pw1 * (x0 * (2*x0)) / 2) + (pw2 * ((1-x0) * (2-2*x0)) / 2)

# Calculate Error of classifier when  $P(w1) = P(w2) = 0.5$ 
err = error_of_classifier(pw1=0.5, pw2=0.5, x0=calculate_decision_boundary(pw1=0.5, pw2=0.5))
print("Error of classifier when  $P(w1)=\{\}$ ,  $P(w2)=\{\}$  is  $\{\}$ ".format(
    0.5, 0.5, err))
```

بخش d)


این بخش دقیقاً مانند بخش b است با این تفاوت که $P(w1) = 0.3$ و $P(w2) = 0.7$ است و به همین خاطر تابع محاسبه‌ی مرز تصمیم بخش دو را با مقدار آرگومان‌های جدید فراخوانده‌ام و مرز تصمیم را رسم کرده‌ام.

```
90 #####
91 # Problem 1- d
92 #####
93 # Plot decision boundary when  $P(w1) = 0.3$ ,  $P(w2) = 0.7$ 
94 plt.plot([calculate_decision_boundary(pw1=.3, pw2=0.7)]*200, y,
95          label='Decision Boundary when  $P(w1)=\{\}$ ,  $P(w2)=\{\}$ '.format(0.3, 0.7)
96          , linestyle='--')
97
98
99 plt.title("Densities And Decision Boundaries, Error when  $P(w1)=P(w2)=0.5$  is:  $\{\}$ ".format(err))
100 plt.xlabel('X')
101 plt.ylabel('Value Of Densities')
102 plt.ylim((-0.75,4))
103 plt.legend()
104 plt.show()
```

همین طور که در تصویر زیر مشاهده می‌شود مرز تصمیم به سمت راست حرکت کرده است تا اثر افزایش $P(w2)$ را بر روی خطا را کم تر کند و خطای کل را مینیمم کند.

در تصویر زیر نتایج قسمت c, b, a و d را مشاهده می‌کنید:

Densities And Decision Boundaries, Error when $P(w1)=P(w2)=0.5$ is: 0.25



خطای classifier در قسمت بالای شکل نمایش داده شده است که برابر 0.25 است.

سوال ۲:

قبل از پاسخگویی به قسمت‌های مختلف سوال تابع `discriminant_function` را شرح می‌دهم که در این سوال و سری تمرین‌های یک از آن استفاده کرده‌ام.

تابع `:discriminant_function`

این تابع یک سری نقطه را می‌گیرد و همین طور مشخصات یک توزیع نرمال را می‌گیرد و بعد `discriminant value` را برای هر نقطه طبق رابطه‌ی زیر محاسبه می‌کند. در زیر کد کامنت گذاری شده‌ی زیر را مشاهده می‌کنید:

```
49 def discriminant_function(mu, covariance, priorProbability, sampleVector):
50     """
51     This function gets an vector of samples and calculates
52     value of discriminant function for each.
53
54     :param mu: a vector of means (list, couple, ...)
55     :param covariance: covariance matrix (list, couple, ...)
56     :param sampleVector: vectors of samples (list, couple, ...)
57     :param priorProbability: prior probability (list, couple, ...)
58     :return: A vector of discriminant of each sample in the sample vector (np.array)
59     """
60     import numpy as np
61
62     # Convert inputs to numpy.matrix()
63     Mu = np.matrix(mu)
64     Cov = np.matrix(covariance)
65     inputVector = np.matrix(sampleVector)
66
67     # Dimension of given normal distribution
68     d = Cov.shape[0]
69
70     # Inverse of covariance matrix
71     invCov = np.linalg.inv(Cov)
72
73     # The part of discriminant function which is equal for different input samples
74     discriminant_value_part2 = -(d/2)*np.log(2*np.pi)-\
75     (1/2)*np.log(np.linalg.det(Cov))+np.log(priorProbability)
76
77     # Output
78     outputVector = []
79
80     # Calculating value of discriminant function for all input samples
81     for i in range(inputVector.shape[0]):
82         # Calculating value of discriminant function for input sample i
83         sampleOutput = (-(1/2) * (inputVector[i] - Mu) * invCov * (inputVector[i] - Mu).transpose())+\
84             discriminant_value_part2
85         outputVector.append(sampleOutput)
86
87     #return an array of discriminant function
88     return np.array(outputVector)
```

بخش (a)

این بخش خواسته است دو تابع g_1 و g_2 را بنویسیم که برابrand با discriminant function توزیع نرمال $p(x|w_1)$ و $p(x|w_2)$ ، برای این منظور دو تابع زیر را نوشته ام که تابع discriminant_function بالا را با مشخصات توزیع نرمال مربوطه فرا می خواند. در تصویر زیر کد کامنت گذاری شده ی این دو تابع را مشاهده می کنید:

```
#####
# Problem 2 - a
#####
def g1(sampleVector):
    """
    This function get a vector of sample and uses
    'discriminant_function' function to calculates
    value of discriminant function for  $p(x|w_1)$  when
     $P(w_1) = 0.6$ , mean = (4, 16) and Sigma =  $4 \cdot I$ 
    :param sampleVector: a vector of sample
    :return: a vector that contains corresponding discriminant
            value for each input sample.
    """
    import numpy as np

    means = [4, 16]
    pw1 = 0.6
    sigma = np.identity(2) * 4

    return discriminant_function(mu=means, covariance=sigma,
                                priorProbability=pw1, sampleVector=sampleVector)
```

```
72 def g2(sampleVector):
73     """
74     This function get a vector of sample and uses
75     'discriminant_function' function to calculates
76     value of discriminant function for  $p(x|w_2)$  when
77      $P(w_1) = 0.4$ , mean = (16, 4) and Sigma =  $4 \cdot I$ 
78     :param sampleVector: a vector of sample
79     :return: a vector that contains corresponding discriminant
80             value for each input sample.
81     """
82     import numpy as np
83
84     means = [16, 4]
85     pw2 = 0.4
86     sigma = np.identity(2) * 4
87
88     return discriminant_function(mu=means, covariance=sigma,
89                                 priorProbability=pw2, sampleVector=sampleVector)
```

بخش (b)

این بخش خواسته است مرز تصمیم را رسم کنیم که این کار را به دو روش انجام داده ام.

روش اول:

همان طور که در تصویر زیر مشاهده می کنید $g_1(x)$ را برابر $g_2(x)$ قرار داده ام و مزر تصمیم را به دست آورده ام:

$$g_1 = -\frac{1}{2} (x - \mu_1)^T \Sigma_1^{-1} (x - \mu_1) - \frac{d}{2} \ln 2\pi - \frac{1}{2} \ln |\Sigma_1| + \ln P(w_1)$$

$$\mu_1 = \begin{bmatrix} 4 \\ 16 \end{bmatrix} \quad P(w_1) = 0.6$$

$$\Sigma_1 = \begin{bmatrix} 4 & 0 \\ 0 & 4 \end{bmatrix}$$

$$d = 2$$

$$g_1 = -\frac{1}{2} (x - \begin{bmatrix} 4 \\ 16 \end{bmatrix})^T \begin{bmatrix} \frac{1}{4} & 0 \\ 0 & \frac{1}{4} \end{bmatrix} (x - \begin{bmatrix} 4 \\ 16 \end{bmatrix}) - \frac{2}{2} \ln 2\pi - \frac{1}{2} \ln(16) + \ln 0.6$$

$$g_2 = -\frac{1}{2} (x - \mu_2)^T \Sigma_2^{-1} (x - \mu_2) - \frac{d}{2} \ln 2\pi - \frac{1}{2} \ln |\Sigma_2| + \ln P(w_2)$$

$$\mu_2 = \begin{bmatrix} 16 \\ 4 \end{bmatrix} \quad P(w_2) = 0.4$$

$$\Sigma_2 = \begin{bmatrix} 4 & 0 \\ 0 & 4 \end{bmatrix}$$

$$d = 2$$

$$g_2 = -\frac{1}{2} (x - \begin{bmatrix} 16 \\ 4 \end{bmatrix})^T \begin{bmatrix} \frac{1}{4} & 0 \\ 0 & \frac{1}{4} \end{bmatrix} (x - \begin{bmatrix} 16 \\ 4 \end{bmatrix}) - \frac{2}{2} \ln 2\pi - \frac{1}{2} \ln(16) + \ln 0.4$$

$$g_1 = g_2 \rightarrow$$

$$-\frac{1}{2} (x - \begin{bmatrix} 4 \\ 16 \end{bmatrix})^T \begin{bmatrix} \frac{1}{4} & 0 \\ 0 & \frac{1}{4} \end{bmatrix} (x - \begin{bmatrix} 4 \\ 16 \end{bmatrix}) + \ln 0.6 = -\frac{1}{2} (x - \begin{bmatrix} 16 \\ 4 \end{bmatrix})^T \begin{bmatrix} \frac{1}{4} & 0 \\ 0 & \frac{1}{4} \end{bmatrix} (x - \begin{bmatrix} 16 \\ 4 \end{bmatrix}) + \ln 0.4$$

$$-\frac{1}{8} (x - \begin{bmatrix} 4 \\ 16 \end{bmatrix})^T (x - \begin{bmatrix} 4 \\ 16 \end{bmatrix}) + \ln 0.6 = -\frac{1}{8} (x - \begin{bmatrix} 16 \\ 4 \end{bmatrix})^T (x - \begin{bmatrix} 16 \\ 4 \end{bmatrix}) + \ln 0.4$$

$$-\frac{1}{8} ((x_1 - 4)^2 + (x_2 - 16)^2) + \ln \frac{0.6}{0.4} + \frac{1}{8} ((x_1 - 16)^2 + (x_2 - 4)^2) = 0$$

$$(x_1 - 4)^2 + (x_2 - 16)^2 - (x_1 - 16)^2 - (x_2 - 4)^2 - 8 \ln \frac{3}{2} = 0$$

$$x_1^2 - 8x_1 + 16 + x_2^2 - 32x_2 + 256 - x_1^2 + 32x_1 - 256 - x_2^2 + 8x_2 - 16 - 8 \ln \frac{3}{2} = 0$$

$$-8x_1 - 32x_2 + 32x_1 + 8x_2 - 8 \ln \frac{3}{2} = 0$$

$$-x_1 - 4x_2 + 4x_1 + x_2 - \ln \frac{3}{2} = 0$$

$$3x_1 - 3x_2 - \ln \frac{3}{2} = 0$$


$$\rightarrow$$

$$x = \begin{bmatrix} x_2 + \frac{1}{3} \ln \frac{3}{2} \\ x_2 \end{bmatrix} = \begin{bmatrix} x_1 \\ x_1 - \frac{1}{3} \ln \frac{3}{2} \end{bmatrix}$$

بعد از آنکه مرز تصمیم را به دست آوردم آن را با استفاده از کد زیر رسم کردم:

```
92 #####
93 # Problem 2 - Needed Function
94 #####
95 import numpy as np
96 import matplotlib.pyplot as plt
97
98 # First manner: Finding equation of x according  $g_1(x) = g_2(x)$ 
99 # which is equal to " $x = [x_1, x_1 - (1/3) * (\ln(3/2))]$ "
100 # feature 1 and 2 points on decision boundary
101 x1 = np.linspace(-50, 50, 200)
102 x2 = [x - (1/3) * (np.log(3/2)) for x in x1]
103
104 # Plot curve
105 plt.figure()
106 plt.plot(x1, x2, label="Decision Boundary")
107 plt.grid()
108 plt.legend()
109 plt.title("Decision Boundary")
110 plt.xlim(-50, 50)
```

که حاصل اجرای کد بالا تصویر زیر است ($x_2 = x_1 - 0.135155036$):



در روش دوم تابع ای به اسم `draw_decision_boundary` نوشته‌ام که مقدار g_1 و g_2 را برای نقاط صفحه ای که می‌خواهیم رسم کنیم را حساب می‌کند و سپس بعد از آن نقطه‌هایی که مقدار $g_1 > g_2$ است را با رنگ متفاوتی از ناحیه‌هایی که در آن $g_1 \leq g_2$ است را نشان می‌دهد. کد تابع را در تصویر زیر می‌بینید:

```
112 # Second manner: Shows areas with  $g_1(x) > g_2(x)$  with
113 # different color that areas which  $g_1(x) \leq g_2(x)$ 
114 def draw_decision_boundary(plot_range):
115     """
116     This function draws discriminant function of to different
117     normal distribution which are given in problem 2 and also,
118     It draws decision boundary
119     :param plot_range: range is a tuple (like: (-2,2)) that determines
120     | range of plot which decision boundary will be drawn on it
121     :return: none
122     """
123     import pylab as pl
124     import numpy as np
125
126     # This determines how many points make the plot.
127     # Number of points on plot: plot_resolution * plot_resolution
128     plot_resolution = 200
129
130     # Make points of plot
131     X, Y = np.mgrid[plot_range[0]:plot_range[1]:plot_resolution*1j,
132     | plot_range[0]:plot_range[1]:plot_resolution*1j]
133
```



```

134 # Concatenate X,Y
135 points = np.c_[X.ravel(), Y.ravel()]
136
137 # Discriminant function for normal distribution 1
138 g1Value = g1(points)
139 g1Value.shape = plot_resolution, plot_resolution
140
141 # Discriminant function for normal distribution 2
142 g2Value = g2(points)
143 g2Value.shape = plot_resolution, plot_resolution
144
145 # Creating a figure and three equal subplot in it
146 fig, axes = pl.subplots(1, 3, figsize=(15, 5))
147 ax1, ax2, ax3 = axes.ravel()
148 for ax in axes.ravel():
149     ax.set_aspect("equal")
150
151 ax1.pcolormesh(X, Y, g1Value)
152 ax2.pcolormesh(X, Y, g2Value)
153
154 # Determining decision boundary
155 ax3.pcolormesh(X, Y, g1Value > g2Value)

```


و سپس این تابع را برای بازه‌ی ۵۰- تا ۵۰+ فراخوانده‌ام:

```

157
158 draw_decision_boundary((-50, 50))
159 plt.show()
160

```

که خروجی آن را در تصویر زیر مشاهده می‌کنید:



سوال ۳:

این سوال یک سری داده‌ی دو بعدی را داده است که هر کدام از داده‌ها مربوط به کلاس یک است یا دو و در رابطه با این داده‌ها سوال‌هایی را مطرح کرده است. کد مربوط به این سوال در پوشه‌ی "problem3" و در فایل "problem3.py" قرار دارد.

در این سوال از تابع‌های زیر استفاده شده است که همان تابع‌هایی هستند که در سری تمرین‌های شماره‌ی یک آن‌ها را نوشتیم و از آن‌ها استفاده کردیم.

تابع `covariance_matrix`:

این تابع تعدادی sample را می‌گیرد و از طریق محاسباتی که در کامنت‌ها توضیح داده شده است ماتریس کواریانس سمپل‌ها را پیدا می‌کند. در تصویر زیر کد کامنت گذاری شده‌ی این تابع را می‌بینید:

```
6 def covariance_matrix(samples):|
7     """
8     This function gets some samples and return its covariance matrix
9     :param samples: each col represents a variable,
10     with observations in the row
11     :return: Corresponding covariance matrix
12     """
13     import numpy as np
14     samplesArray = np.asarray(samples)
15     samplesArray = np.transpose(samplesArray)
16
17     # Cov function calculates covariance it this way:
18     #  $X_{new}(k) = X(k) - \mu$ 
19     #  $B = [X_{new}(1), X_{new}(2), \dots, X_{new}(n)]$ 
20     #  $Cov = \frac{1}{(n-1)} B * transpose(\bar{B})$ 
21     return np.cov(samplesArray).tolist()
```

تابع `mean_vector`:

این تابع تعدادی sample را می‌گیرد و میانگین آن‌ها را محاسبه می‌کند و به عنوان خروجی یک لیست بر می‌گرداند که برابر است با میانگین سمپل‌ها، در زیر کد این تابع را مشاهده می‌کنید:

```

24 def mean_vector(X):
25     """
26     :param X: each col represents a variable,
27               with observations in the row
28     :return: return a list that contains mean of each col
29     """
30     import numpy as np
31     means = np.mean(X, axis=0)
32     return means.tolist()

```

تابع **mean_and_covariance**:

این تابع سمپل‌ها را می‌گیرد و دو تابع بالا را فرا می‌خواند و میانگین و ماتریس کواریانس داده‌ها را در قالب یک دیکشنری که شامل کلیدهای means و covariance هست را برمی‌گرداند. در زیر کد کامنت گذاری شده‌ی این تابع را مشاهده می‌کنید:

```

35 def mean_and_covariance(samples):
36     """
37     This function gets some samples and then it finds
38     corresponding Covariance and mean of their normal distribution.
39     :param samples: samples.each col represents a variable,
40                     with observations in the row
41     :return: a dictionary with keys: {'means': , 'covariance'}
42     """
43     dic = {}
44     dic['means'] = mean_vector(samples)
45     dic['covariance'] = covariance_matrix(samples)
46     return dic

```

تابع **discriminant_function**:

این تابع یک سری نقطه را می‌گیرد و همین‌طور مشخصات یک توزیع نرمال را می‌گیرد و بعد discriminant value را برای هر نقطه طبق رابطه‌ی زیر محاسبه می‌کند.

$$g_i(\mathbf{x}) = -\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu}_i)^t \boldsymbol{\Sigma}_i^{-1}(\mathbf{x} - \boldsymbol{\mu}_i) - \frac{d}{2} \ln 2\pi - \frac{1}{2} \ln |\boldsymbol{\Sigma}_i| + \ln P(\omega_i). \quad (47)$$

در زیر کد کامنت گذاری شده‌ی زیر را مشاهده می‌کنید:

```

49 def discriminant_function(mu, covariance, priorProbability, sampleVector):
50     """
51     This function gets an vector of samples and calculates
52     value of discriminant function for each.
53
54     :param mu: a vector of means (list, couple, ...)
55     :param covariance: covariance matrix (list, couple, ...)
56     :param sampleVector: vectors of samples (list, couple, ...)
57     :param priorProbability: prior probability (list, couple, ...)
58     :return: A vector of discriminant of each sample in the sample vector (np.array)
59     """
60     import numpy as np
61
62     # Convert inputs to numpy.matrix()
63     Mu = np.matrix(mu)
64     Cov = np.matrix(covariance)
65     inputVector = np.matrix(sampleVector)
66
67     # Dimension of given normal distribution
68     d = Cov.shape[0]
69
70     # Inverse of covariance matrix
71     invCov = np.linalg.inv(Cov)
72
73     # The part of discriminant function which is equal for different input samples
74     discriminant_value_part2 = -(d/2)*np.log(2*np.pi)-\
75     (1/2)*np.log(np.linalg.det(Cov))+np.log(priorProbability)
76
77     # Output
78     outputVector = []
79
80     # Calculating value of discriminant function for all input samples
81     for i in range(inputVector.shape[0]):
82         # Calculating value of discriminant function for input sample i
83         sampleOutput = (-(1/2) * (inputVector[i] - Mu) * invCov * (inputVector[i] - Mu).transpose())+\
84             discriminant_value_part2
85         outputVector.append(sampleOutput)
86
87     #return an array of discriminant function
88     return np.array(outputVector)

```

تابع draw_decision_boundary_2d_normal:

این تابع میانگین و ماتریس کواریانس و prior دو کلاس را می‌گیرد همچنین بازه‌ای را که می‌خواهد مرز تصمیم‌گیری را در آن رسم کند را به عنوان ورودی می‌گیرد. بعد در آن بازه مقدار discriminant value را برای هر دو توزیع حساب می‌کند و در آخر سه تصویر در بازه‌ی مشخص شده رسم می‌کند.

(۱) مقدار discriminant value برای نقاط، توزیع اول

(۲) مقدار discriminant value برای نقاط، توزیع دوم

(۳) برای نقاطی که در توزیع اول مقدار discriminant value آن‌ها بیشتر از توزیع دوم است را با رنگی متفاوت می‌کشد.

در زیر کد کامنت گذاری شده‌ی این تابع را مشاهده می‌کنید:


```

91 def draw_decision_boundary_2d_normal(mu1, cov1, prior1, mu2, cov2, prior2, plot_range):
92     """
93     This function draws discriminant function of two different
94     normal distribution and also, It draws decision boundary
95     :param mu1: means vector of distribution 1
96     :param cov1: covariance matrix of distribution 1
97     :param prior1: prior probability of distribution 1
98     :param mu2: means vector of distribution 2
99     :param cov2: covariance matrix of distribution 2
100     :param prior2: prior probability of distribution 2
101     :param plot_range: range is a tuple (like: (-2,2)) that determines
102         range of plot which decision boundary will be drawn on it
103     :return: none
104     """
105     import pylab as pl
106     import numpy as np
107
108     # This determines how many points make the plot.
109     # Number of points on plot: plot_resolution * plot_resolution
110     plot_resolution = 300
111
112     # Make points of plot

```

```

113     X, Y = np.mgrid[plot_range[0]:plot_range[1]:plot_resolution*1j,
114                    plot_range[0]:plot_range[1]:plot_resolution*1j]
115
116     # Concatenate X,Y
117     points = np.c_[X.ravel(), Y.ravel()]
118
119     # Inverse of matrix cov1, for preventing repetition of computation
120     invC = np.linalg.inv(cov1)
121
122     # Discriminant function for normal distribution 1
123     g1 = discriminant_function(mu1, cov1, prior1, points)
124     g1.shape = plot_resolution, plot_resolution
125
126     # Inverse of matrix cov2, for preventing repartition of computation
127     invC = np.linalg.inv(cov2)
128
129     # Discriminant function for normal distribution 2
130     g2 = discriminant_function(mu2, cov2, prior2, points)
131     g2.shape = plot_resolution, plot_resolution
132
133     # Creating a figure and three equal subplot in it

```

```

134 fig, axes = plt.subplots(1, 3, figsize=(15, 5))
135 ax1, ax2, ax3 = axes.ravel()
136 for ax in axes.ravel():
137     ax.set_aspect("equal")
138
139 ax1.pcolormesh(X, Y, g1)
140 ax2.pcolormesh(X, Y, g2)
141
142 # Determining decision boundary
143 ax3.pcolormesh(X, Y, g1 > g2)
144
145 plt.show()

```

اکنون که تابع‌های استفاده شده را شرح دادم به بخش‌های مختلف سوال می‌پردازم.

بخش A)

این بخش خواستار محاسبه‌ی prior probability هر کدام از کلاس‌ها است. برای این منظور کد زیر را نوشته‌ام که تعداد سмпل‌های هر کلاس نسبت به کل سмпل‌ها را به دست می‌آورد:

```

154 #####
155 # Problem 3- a
156 #####
157 classesPrior = {}
158 numberOfAllSamples = 0
159 # Count number of all samples in all classes
160 for key in classes:
161     numberOfAllSamples += len(classes[key])
162
163 # calculate and print prior probability of each class
164 for key in classes:
165     classesPrior[key] = len(classes[key])/numberOfAllSamples
166     print('Prior of w{} is :{}'.format(key, classesPrior[key]))

```

خروجی اجرای این قسمت از کد را در تصویر زیر مشاهده می‌کنید:

```

Prior of w1 is :0.5
Prior of w2 is :0.5

```

بخش b)

این بخش خواسته است که میانگین و ماتریس کواریانس هر کلاس را محاسبه کنیم، برای این منظور کد زیر را نوشته‌ام:

```
169 #####
170 # Problem 3- b
171 #####
172 # Find mean and covariance of each class
173 classesMeanAndCov = {}
174 for key in classes:
175     # This function return mean and cov matrix in a dictionary
176     # data structure, {'means': , 'covariance': }
177     classesMeanAndCov[key] = mean_and_covariance(classes[key])
178
179 # print mean an covariance for each class
180 for key in classesMeanAndCov:
181     print('W{:}\nmeans is: {},\ncovariance matrix is: {}'.format(
182         key, classesMeanAndCov[key]['means'], classesMeanAndCov[key]['covariance']))
```

خروجی اجرای این بخش از کد را در تصویر زیر مشاهده می کنید:

```
W1:
means is: [1.8333333333333333, 1.5],
covariance matrix is: [[2.166666666666667, 1.1], [1.1, 1.1]]
W2:
means is: [8.166666666666666, 9.333333333333334],
covariance matrix is: [[1.366666666666667, -0.066666666666667], [-0.066666666666667, 1.066666666666669]]
```

بخش c)


این بخش خواستار رسم decision boundary شده است، به این منظور تابع رسم مرز تصمیم را که در بالا شرح دادم را در کد به شکل زیر فراخواندم:

```

185 #####
186 # Problem 3- C
187 #####
188 # Draw decision boundary which separate class1 and class2
189 print("Drawing decision boundary takes several second, ...")
190 draw_decision_boundary_2d_normal(classesMeanAndCov[1]['means'],
191                                 classesMeanAndCov[1]['covariance'],
192                                 classesPrior[1],
193                                 classesMeanAndCov[2]['means'],
194                                 classesMeanAndCov[2]['covariance'],
195                                 classesPrior[2],
196                                 (-100,100)
197                                 )

```

خروجی اجرای این قسمت از کد را در تصویر زیر مشاهده می کنید (بازه ی -100 تا 100) :



بخش d)

بله تحت تاثیر قرار می دهد. اگر به صورت zero-one loss نباشد مرز تصمیم حرکت می کند به طوری که مساحت قسمتی که وزن خطای کمتری دارد کمتر می شود و مساحت قسمتی که ضریب و وزن خطای بیشتر دارد بیشتر می شود.

سوال ۴:

بخش a, b, c

برای این سوال برنامه‌ای نوشتم که برای دو توزیع نرمال، برای هر کدام ۱۰۰۰۰ نمونه ایجاد می‌کند و هر نمونه از توزیع اول را با نمونه‌ی متناظر در توزیع دوم جمع می‌کند تا ۱۰۰۰۰ نمونه برای توزیع سوم ایجاد شود و بعد میانگین و واریانس توزیع سوم را حساب می‌کند و در نهایت Histogram هر سه توزیع را رسم می‌کنم و این کار را برای ۵ بار با داده‌های مختلف تکرار می‌کند. در زیر کد کامنت گذاری شده‌ی این برنامه را می‌بینید:

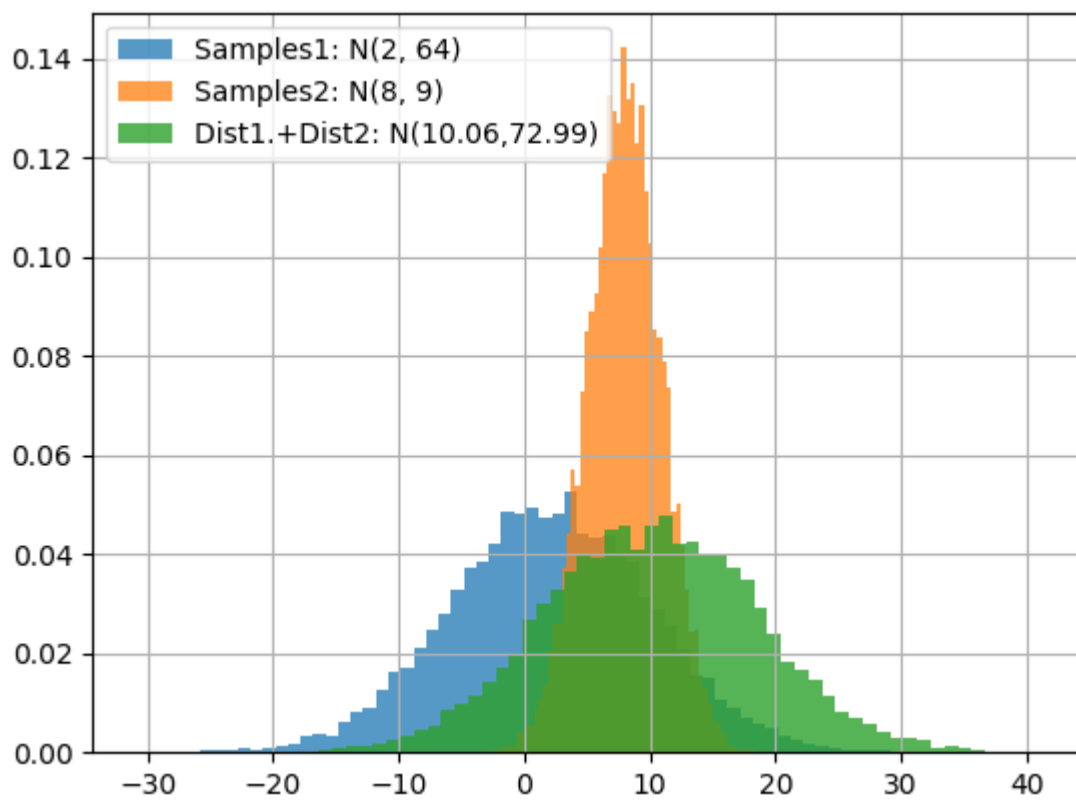
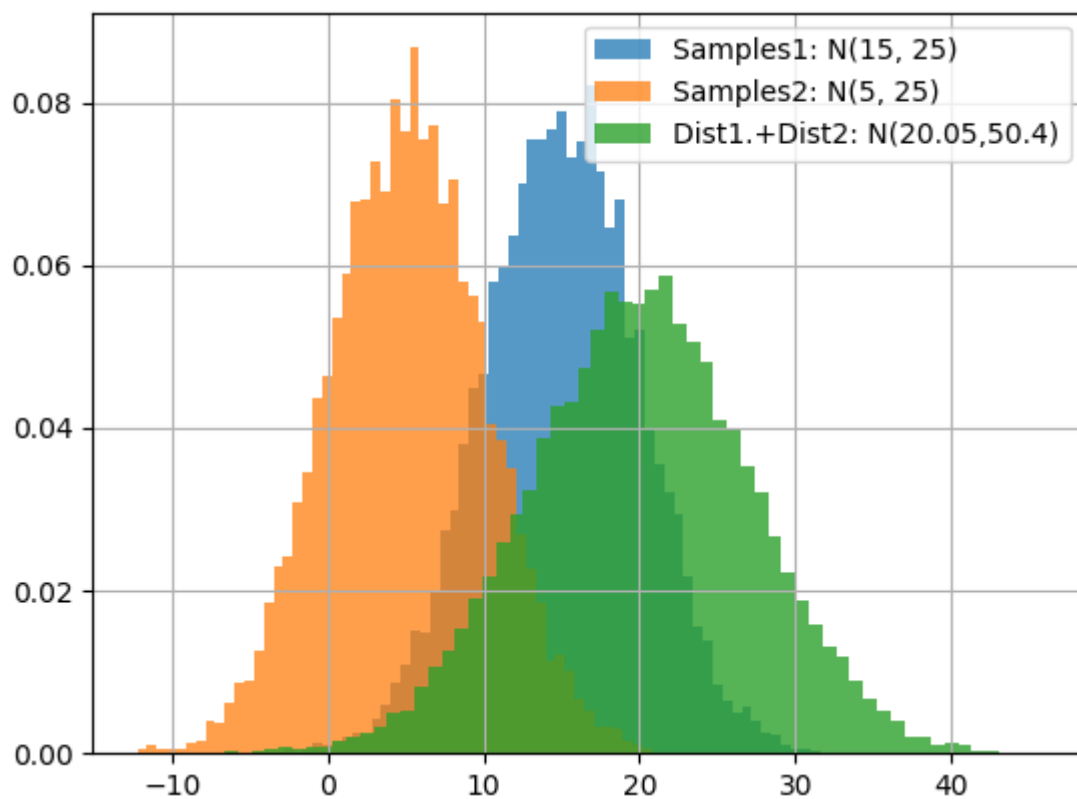
```
1 import numpy as np
2 import matplotlib.pyplot as plt
3
4 # Number of samples
5 n = 10000
6
7 # Different value of mean and standard deviation
8 # for two normal distributions
9 Means1 = [-30, 15, 2, 6, 0]
10 Means2 = [30, 5, 8, 12, 0]
11 Sigma1 = [3, 5, 8, 10, 1]
12 Sigma2 = [30, 5, 3, 2, 1]
13
14 # Do experiment with different values
15 for i in range(5):
16     mu1 = Means1[i]
17     sigma1 = Sigma1[i]
18
19     mu2 = Means2[i]
20     sigma2 = Sigma2[i]
21
22     # Draw samples from distribution 1
```



```

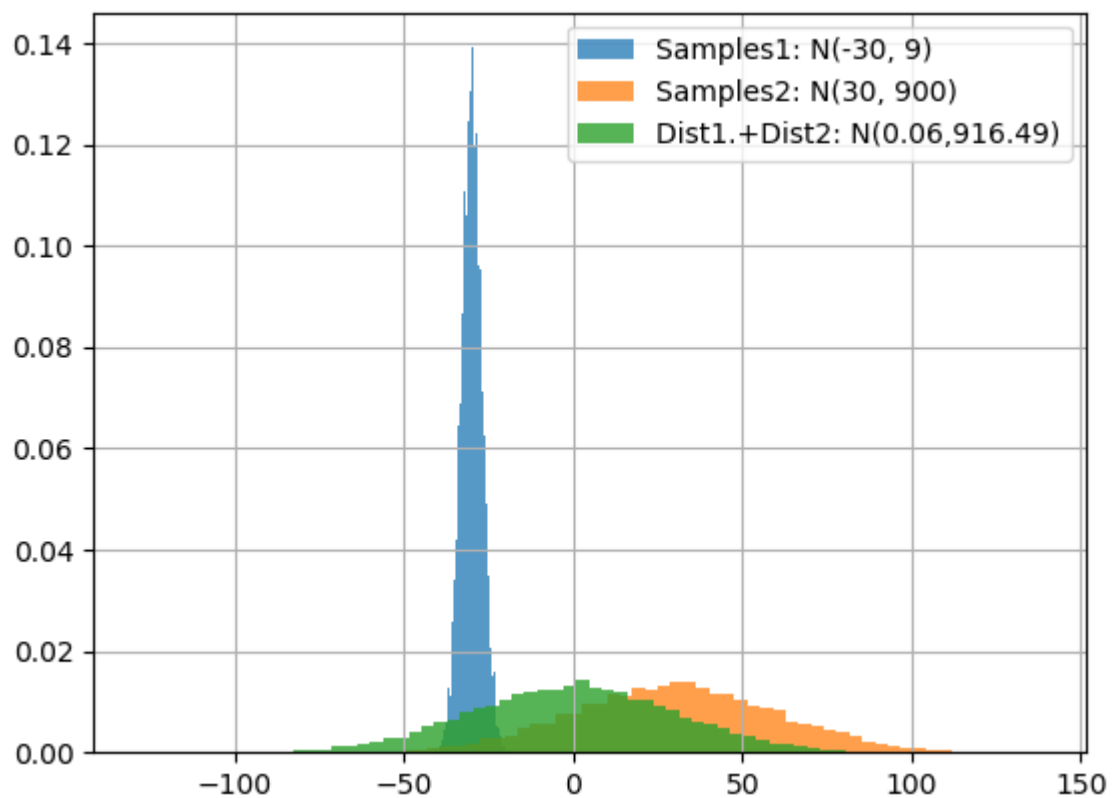
23 samples1 = np.random.normal(loc=mu1, scale=sigma1, size=n)
24
25 # Draw samples from distribution 2
26 samples2 = np.random.normal(loc=mu2, scale=sigma2, size=n)
27
28 # Add each element of sample1 to corresponding element of sample2
29 samples3 = samples1 + samples2
30
31 # Mean of samples3
32 mu3 = np.mean(samples3)
33
34 # Var of samples3
35 var3 = np.cov(samples3)
36
37 plt.figure()
38 # Plot histogram of sample form distribution N(mu1, sigma1^2)
39 plt.hist(x=samples1, bins='auto', normed=True, alpha=0.75,
40         label='Samples1: N({}, {})'.format(mu1, sigma1 ** 2))
41
42 plt.hist(x=samples2, bins='auto', normed=True, alpha=0.75,
43         label='Samples2: N({}, {})'.format(mu2, sigma2 ** 2))
44
45 # Plot histogram of sample form samples1+samples2
46 plt.hist(x=samples3, bins='auto', normed=True, alpha=0.8,
47         label='Dist1.+Dist2: N({}, {})'.format(np.round(mu3, 2), np.round(var3, 2)))
48
49 plt.grid()
50 plt.legend()
51
52 plt.show()

```

بعد از اجرای این کد ۵ شکل رسم می‌شود که هر شکل حاوی histogram دو توزیع نرمال و توزیع جدید حاصل از جمع اجزای آن دو است و همین طور در قسمت label ها میانگین و واریانس دو توزیع اول و میانگین و واریانس تخمینی توزیع سوم (رنگ سبز) نمایش داده می‌شود:







همین طور که مشاهده می کنید در هر پنج تصویر

$$\text{mean3} \approx \text{mean1} + \text{mean2}$$

$$\text{variance3} \approx \text{variance1} + \text{variance2}$$

میانگین و واریانس جدید تقریباً برابر با مجموع میانگین و واریانس دو توزیع نرمال اول است.

سوال ۵:

قبل از پاسخگویی به بخش های مختلف سوال ابتدا تابع هایی را که استفاده کرده ام را معرفی می کنم.

تابع های `covariance_matrix` , `mean_vector`, `mean_and_covariance`, `draw_decision_boundary_2d_normal` و `discriminant_function` را در سوال سه استفاده کرده ام و آن ها را ان جا توضیح داده ام.

تابع `bhattacharyya_bound` شباهت دو توزیع نرمال را حساب می کند که باندی برای خطا است کد کامنت گذاری شده ی این تابع را در تصویر زیر مشاهده می کنید (این تابع را در سری تمرین های شماره ی یک استفاده کرده ام):

```
148 def bhattacharyya_bound(normalDist1, normalDist2):
149     """
150     This measure shows similarities between two
151     distribution and Also it's a error bound.
152     :param normalDist1: is dictionary that contains
153     | these keys {'means', 'covariance', 'name', 'prior'}
154     :param normalDist2: is dictionary that contains
155     | these keys {'means', 'covariance', 'name', 'prior'}
156     :return: return a scalar
157     """
158     import numpy as np
159
160     # Convert data to proper form
161     mean1 = np.asmatrix(normalDist1['means'])
162     mean2 = np.asmatrix(normalDist2['means'])
163     cov1 = np.asmatrix(normalDist1['covariance'])
164     cov2 = np.asmatrix(normalDist2['covariance'])
165
166     # Average of two covariances
167     covAve = (cov1 + cov2) / 2
168
169     # Subtract of means
170     meanSub = mean2 - mean1
171
172     # Calculate the bound
173     bound = (np.sqrt(normalDist1['prior'] * normalDist2['prior'])) * (
174     | np.exp(-1 * ((1/8) * (meanSub * np.linalg.inv(covAve) * np.transpose(meanSub)) +
175     | (1/2) * np.log(
176     | np.linalg.det(covAve)/np.sqrt(np.linalg.det(cov1) *
177     | np.linalg.det(cov2))
178     | )))
179
180     #return bound
181     return bound.tolist()[0][0]
```

بخش a)

این بخش دو توزیع نرمال و `prior` هایشان را داده است و مرز تصمیم را خواسته است که رسم کنیم. در تصویر زیر محاسبه ی مرز تصمیم را مشاهده می کنید:

$$g_1 = -\frac{1}{2}(x-\mu_1)^T \Sigma_1^{-1}(x-\mu_1) - \frac{d}{2} \ln 2\pi - \frac{1}{2} \ln |\Sigma_1| + \ln p(w_1)$$

$$\mu_1 = \begin{bmatrix} 1 \\ 0 \end{bmatrix} \quad p(w_1) = 0.5 \quad \text{covariance matrix} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} \quad d=2$$

$$g_1 = -\frac{1}{2}(x - \begin{bmatrix} 1 \\ 0 \end{bmatrix})^T \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} (x - \begin{bmatrix} 1 \\ 0 \end{bmatrix}) - \frac{2}{2} \ln 2\pi - \frac{1}{2} \ln 1 + \ln(0.5)$$

$$g_2 = -\frac{1}{2}(x-\mu_2)^T \Sigma_2^{-1}(x-\mu_2) - \frac{d}{2} \ln 2\pi - \frac{1}{2} \ln |\Sigma_2| + \ln p(w_2)$$

$$\mu_2 = \begin{bmatrix} 1 \\ 1 \end{bmatrix} \quad p(w_2) = 0.5 \quad \text{covariance matrix} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} \quad d=2$$

$$g_2 = -\frac{1}{2}(x - \begin{bmatrix} 1 \\ 1 \end{bmatrix})^T \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} (x - \begin{bmatrix} 1 \\ 1 \end{bmatrix}) - \frac{2}{2} \ln 2\pi - \frac{1}{2} \ln 1 + \ln(0.5)$$

$$g_1(x) = g_2(x) \Rightarrow$$

$$-\frac{1}{2}(x)^T \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} (x) = -\frac{1}{2}(x - \begin{bmatrix} 1 \\ 1 \end{bmatrix})^T \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} (x - \begin{bmatrix} 1 \\ 1 \end{bmatrix}) \Rightarrow$$

$$x_1^2 + x_2^2 = (x_1 - 1)^2 + (x_2 - 1)^2 \Rightarrow$$

$$x_1^2 + x_2^2 = x_1^2 - 2x_1 + 1 + x_2^2 - 2x_2 + 1 \Rightarrow$$

$$\boxed{x_1 = -x_2 + 1} \Rightarrow x = \begin{bmatrix} x_1 \\ -x_1 + 1 \end{bmatrix}$$

که برای رسم این خط کد زیر را نوشته ام:


```
#####
# Problem 5- a
#####
# Draw decision boundary
# As I've shown in report when we put  $g_1(x) = g_2(x)$ 
# we gain  $x_2 = -x_1 + 1$ 
import numpy as np
import matplotlib.pyplot as plt

# Generate 200 points for drawing decision boundary
x1 = np.linspace(-5, 5, 200)

# Calculate feature x2 according  $x_2 = -x_1 + 1$ 
x2 = [(-1*x)+1 for x in x1]

plt.plot(x1, x2, label='x2 = -x1 + 1')
plt.legend()
plt.grid()
plt.xlim(-5, 5)
plt.title("Decison boundary for problem5-parta")
plt.show()
```

بعد از اجرای این قطعه از کد نمودار زیر ساخته می شود:



بخش (b)

این بخش از سوال خواسته است Bhattacharyya error bound را حساب کنیم که به همین منظور تابع `bhattacharyya_bound` را به صورت زیر فراخوانده‌ایم:

```
205 #####
206 # Problem 5- b
207 #####
208 normalDist1 = {'means': [0, 0], 'covariance': [[1, 0],[0, 1]], 'name': 'w1','prior': 0.5}
209 normalDist2 = {'means': [1, 1], 'covariance': [[1, 0],[0, 1]], 'name': 'w2','prior': 0.5}
210
211 # calculate bhattacharyya bound
212 bhb = bhattacharyya_bound(normalDist1, normalDist2)
213 print("Bhattacharyya Bound is: ", bhb)
214 |
```

حاصل اجرای کد بالا را در تصویر زیر مشاهده می‌کنید:

```
/home/bat/anaconda3/bin/python /home/bat/Dropbox/codes/pythonCoc
Bhattacharyya Bound is: 0.38940039153570244
```


بخش (c)

بخش (d)

برای رسم decision boundary توزیع های نرمال داده شده تابع `draw_decision_boundary_2d_normal` فراخوانده‌ام که دو توزیع نرمال و prior آن ها را می‌گیرد همان طور بازه‌ای که باید مرز تصمیم را رسم کند را می‌گیرد و برای نقطه‌های درون بازه discriminant value را برای دو توزیع نرمال یک و دو حساب می‌کند و ناحیه‌های که $g1 > g2$ را با رنگ متفاوتی از ناحیه‌هایی که $g1 \leq g2$ است را نشان می‌دهد و مرز تصمیم گیری برابر می‌شود با محل تلاقی این دو ناحیه. کد زیر را جهت فراخوانی تابع رسم مرز تصمیم گیری و حد Bhattacharyya نوشته‌ام:

```
216 #####
217 # Problem 5- d
218 #####
219 print('wait, drawing decision boundary takes several second ...')
220 draw_decision_boundary_2d_normal(mu1=[0, 0], cov1=[[2, 0.5],[0.5, 2]], prior1=0.5,
221                                mu2=[1, 1], cov2=[[5, 2],[2, 5]], prior2=0.5,
222                                plot_range=(-5, 5))
223
224 normalDist1 = {'means': [0, 0], 'covariance': [[2, 0.5],[0.5, 2]], 'name': 'w1','prior': 0.5}
225 normalDist2 = {'means': [1, 1], 'covariance': [[5, 2],[2, 5]], 'name': 'w2','prior': 0.5}
226
227 # calculate bhattacharyya bound
228 bhb = bhattacharyya_bound(normalDist1, normalDist2)
229 print("5-d) Bhattacharyya Bound is: ", bhb)
230
```

بعد از اجرای کد بالا نتایج زیر به دست می آید:



9

wait, drawing decision boundary takes several second ...
5-d) Bhattacharyya Bound is: 0.4322519655344438

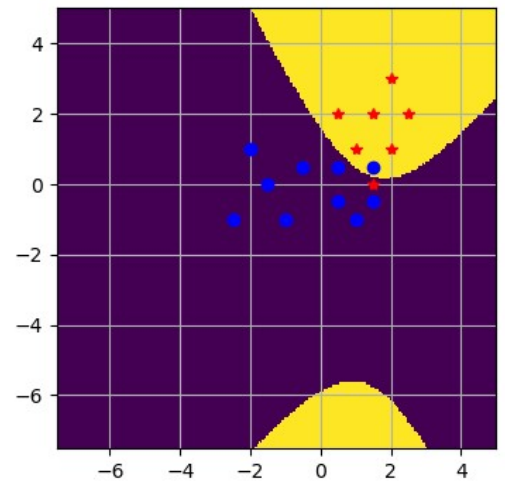


سوال ۶:

کدهای این سوال در پوشه‌ی problem6 و در فایل problem6.py قرار دارند. برای این سوال از تابع‌های زیر استفاده کرده‌ام:

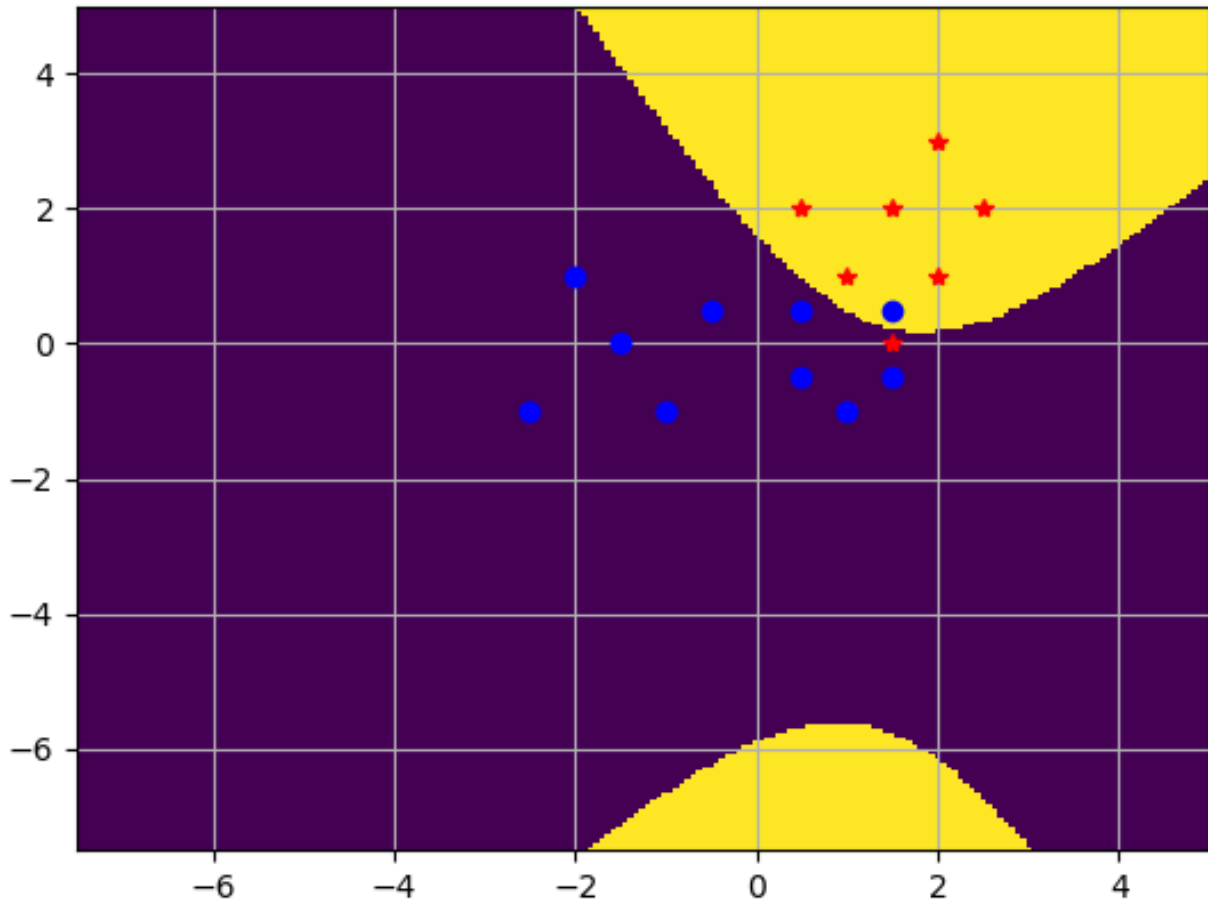
covariance_matrix, mean_vector, mean_and_covariance, discriminant_function و draw_decision_boundary_2d_normal. draw_decision_boundary_2d_normal کدهای آن‌ها را در سوال‌های قبل استفاده کرده‌ام و همان‌جا آن‌ها را توضیح داده‌ام به همین دلیل از آوردن کد آن‌ها در این سوال خودداری می‌کنم. فقط در تابع draw_decision_boundary_2d_normal تغییر کوچکی ایجاد کردم و در آرگمان‌ها sample‌های کلاس w1 و w2 را می‌گیرم تا علاوه بر رسم مرز تصمیم sample‌ها را هم بر روی صفحه رسم کنم. در تصویر زیر فراخوانی این تابع‌ها را برای پیدا کردن میانگین و ماتریس کواریانس توزیع‌ها و پیدا کردن مرز تصمیم را مشاهده می‌کنید:

```
179 #####
180 # Problem 6-|
181 #####
182
183 # mean and covariance matrix w1:
184 normal_dist_w1 = mean_and_covariance(w1)
185
186 # mean and covariance matrix w2:
187 normal_dist_w2 = mean_and_covariance(w2)
188
189 # Find Prior probabilities of w1 and w2
190 prior1 = len(w1) / (len(w1)+len(w2))
191 prior2 = len(w2) / (len(w1)+len(w2))
192
193 print('Drawing takes several seconds, Wait ...')
194 # Draw decision boundary and samples
195 draw_decision_boundary_2d_normal(mu1=normal_dist_w1['means'], cov1=normal_dist_w1['covariance'], prior1= prior1,
196                                 mu2=normal_dist_w2['means'], cov2=normal_dist_w2['covariance'], prior2= prior2,
197                                 plot_range=(-7.5, 5),
198                                 samplesw1= w1,
199                                 samplesw2= w2
200                                 )
```

نتیجه‌ی حاصل اجرای کد بالا را در تصویر زیر مشاهده می‌کنید. دو تصویر سمت چپ مقدار discriminat values کلاس w1 و w2 است در بازه‌ی مشخص شده برای رسم است و تصویر سمت راست تصویر مرز تصمیم و samples است.



تصویری بزرگ تر از مرز تصمیم و سمپل‌ها:



سوال ۷:

کدهای مربوط به این سوال در پوشه‌ی problem7 و در فایل problem7.py قرار دارند.

بخش a, b

این دو بخش از سوال خواسته است که توزیع دو کلاس ضرب در prior هایشان را رسم کنیم و مرز تصمیم‌ها را مشخص کنیم. برای رسم موارد خواسته شده کد زیر را نوشته‌ام:
تابع c1 مقدار توزیع نرمال کلاس یک را در نقطه‌ی x را مشخص می‌کند.

```
1 #####
2 # Problem 7 - a, b
3 #####
4
5
6 def c1(x):
7     """
8     Determine value of x in uniform distribution (2, 4)
9     :param x: x is a given point
10    :return: value of point x in U(2, 4)
11    """
12    if(x >= 2 and x <= 4):
13        return 1/2
14    else:
15        return 0
```

تابع c2 مقدار توزیع نرمال کلاس دو را در نقطه‌ی x را مشخص می‌کند.

```
18 def c2(x):
19     """
20     Determine value of x in exponential distribution (lambda = 1)
21     :param x: x is a given point
22     :return: value of point x in exponential(lambda = 1)
23     """
24     import numpy as np
25     return np.exp(-1 * x)
```

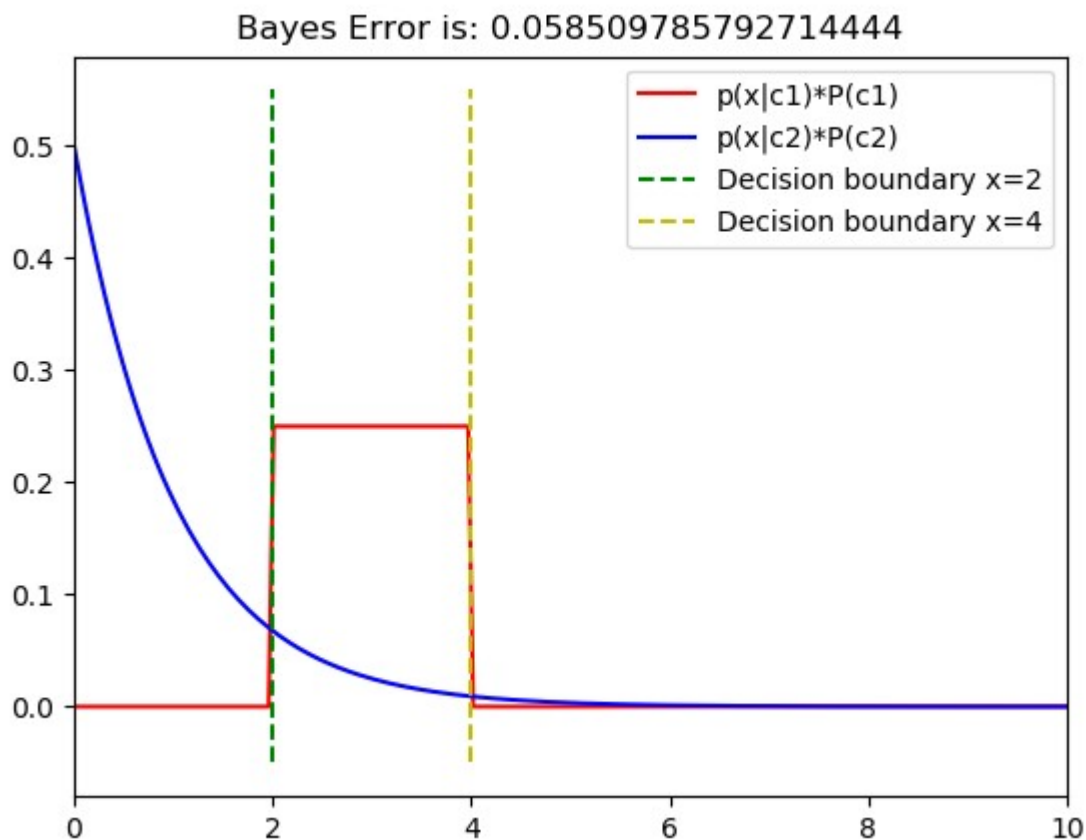
در ادامه در بازه‌ی 0 تا 10 دو یست نقطه ایجاد کرده‌ام و در آن نقطه‌ها میزان توزیع هر دو کلاس ضرب در prior هایشان را حساب کرده‌ام و بعد آن‌ها را رسم کرده‌ام:

```

28 import numpy as np
29 import matplotlib.pyplot as plt
30
31 priorC1 = priorC2 = 0.5
32
33 # Generate 200 point for drawing curves between 0 & 10
34 x = np.linspace(0, 10, 200)
35
36 # Generate density of class1
37 density1 = [c1(point) * priorC1 for point in x]
38
39 # Generate density of class2
40 density2 = [c2(point) * priorC2 for point in x]
41
42 # Plot densities
43 plt.plot(x, density1, 'r-', label='p(x|c1)*P(c1)')
44 plt.plot(x, density2, 'b-', label='p(x|c2)*P(c2)')
45
46 # Plot decision boundaries
47 y = np.linspace(-0.05, 0.55, 100)
48 plt.plot([2]*100, y, 'g--', label='Decision boundary x=2')
49 plt.plot([4]*100, y, 'y--', label='Decision boundary x=4')
50
51 #plt.grid()
52 plt.legend()
53 plt.xlim(0, 10)

```

حاصل اجرای کد بالا را در تصویر زیر مشاهده می کنید:



همین طور که مشاهده می کنید دو خط جدا کننده داریم. ناحیه ی بین 2 و 4 برابر است با ناحیه ی کلاس یک و باقی محور x مربوط به کلاس دو می شود زیرا تابع دو در آن نقاط مقدار بیشتر دارد.

بخش C)

مقدار خطا برابر است با مساحت زیر خط e^{-x} ضرب در prior کلاس دو. ولی از آنجایی که انتگرال e^{-x} شکل مشخصی ندارد باید آن را تخمین بزنیم که برای این کار از **بسط تیلور** به صورت زیر استفاده کرده ام:

$$\text{Taylor } e^x: e^x = 1 + x + \frac{(x^2)}{2!} + \frac{(x^3)}{3!} + \dots \implies$$

$$\text{Taylor } e^{-x}: e^{-x} = 1 - x + \frac{(x^2)}{2!} - \frac{(x^3)}{3!} + \dots \implies$$

$$\int e^{-x} = \text{Integral } 1 - x + \frac{(x^2)}{2!} - \frac{(x^3)}{3!} + \dots \implies$$

which is equal to

$$\int e^{-x} = [x - \frac{(x^2)}{2!} + \frac{(x^3)}{3!} - \frac{(x^4)}{4!} + \dots] \text{ on interval } [a, b]$$

که با توجه به رابطه ی بالا تابع زیر را نوشته ام که مقدار تقریبی خطا را حساب می کند:


```

57 #####
58 def approximate_error(a, b, priorOfClassC2):
59     """
60     This function approximates Integral  $e^{-x}$ 
61     according to below relations
62     taylor  $e^x$ :  $e^x = 1 + x + (x^2)/2! + (x^3)/3! + \dots$ 
63     taylor  $e^{-x}$ :  $e^{-x} = 1 - x + (x^2)/2! - (x^3)/3! + \dots$ 
64
65     Integral  $e^{-x} = \text{Integral } 1 - x + (x^2)/2! - (x^3)/3! + \dots$ 
66     which is equal to
67     Integral  $e^{-x} = [x - (x^2)/2! + (x^3)/3! - (x^4)/4! + \dots]$  on interval  $[a,b]$ 
68
69     :param a: start of integral interval
70     :param b: end of integral interval
71     :param priorOfClassC2: prior of class c2 for multiplying it to area under
72          $e^{-x}$ 
73     :return: approximate integral
74     """
75     # Calculate Integral according to above formula
76     factorial = 1
77     valueOfIntegral = 0
78     sign = 1
79     for i in range(1, 21):
80         valueOfIntegral += sign * (b**i - a**i) / factorial
81         sign *= -1
82         factorial *= i+1
83
84     return valueOfIntegral * priorOfClassC2

```

که بعد از اجرای کد بالا میزان خطا هم در بالای نمودار نمایش داده می شود (خروجی قسمت قبل) و هم بر روی صفحه:

```

87 plt.title('Bayes Error is: {}'.format(approximate_error(a=2, b=4, priorOfClassC2=0.5)))
88 plt.show()
89
90
91 print("> Approximate Error is: ",
92       approximate_error(a=2, b=4, priorOfClassC2=0.5))
93

```

خروجی اجرای قسمت بالا:

> Approximate Error is: 0.058509785792714444

(بخش a)

تابع میانگین و کواریانس یک توزیع نرمال را می‌گیرد و n سمپل از آن بیرون می‌کشد:

```

5 #####
6 # Computer exercise 7-a
7 #####
8
9
10 def d_normal_distribution(mu, covMat, n):
11     """
12     D-dimensional normal distribution function,
13     it draws samples from a D-dimensional normal distribution.
14     :param
15     (mu) mean vector,
16     (covMat) covariance matrix,
17     (n) number of samples that should be drawn.
18     :return Output:
19     each entry out[i,j,...,:] is an D-dimensional value drawn from normal distribution.
20     An example of this function:
21     d_normal_distribution(mu=[0,0], covMat=[[1, 0],[0, 100]], n=10)
22     """
23     import numpy as np
24     # Use multivariate normal distribution of numpy package
25     return np.random.multivariate_normal(mean=mu, cov=covMat, size=n, check_valid='ignore').tolist()

```

(بخش b)

همین طور که در تصویر زیر مشاهده می‌کنید مرز تصمیم‌گیری برابر است با $x_0 = 0$:

$$g_1 = -\frac{1}{2} (x - \mu_1)^T \Sigma_1^{-1} (x - \mu_1) - \frac{1}{2} \ln 2\pi - \frac{1}{2} \ln |\Sigma_1| + \ln(p(\omega_1))$$

$$\mu_1 = \begin{bmatrix} 1 \\ 0 \end{bmatrix} \quad p(\omega_1) = 0.5 \quad \text{covariance matrix} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} \quad d=2$$

$$g_1 = -\frac{1}{2} (x - \begin{bmatrix} 1 \\ 0 \end{bmatrix})^T \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} (x - \begin{bmatrix} 1 \\ 0 \end{bmatrix}) - \frac{1}{2} \ln 2\pi - \frac{1}{2} * 1 + \ln(0.5)$$

$$g_2 = -\frac{1}{2} (x - \mu_2)^T \Sigma_2^{-1} (x - \mu_2) - \frac{1}{2} \ln 2\pi - \frac{1}{2} \ln |\Sigma_2| + \ln(p(\omega_2))$$

$$\mu_2 = \begin{bmatrix} -1 \\ 0 \end{bmatrix} \quad p(\omega_2) = 0.5 \quad \text{covariance matrix} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} \quad d=2$$

$$g_2 = -\frac{1}{2} (x - \begin{bmatrix} -1 \\ 0 \end{bmatrix})^T \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} (x - \begin{bmatrix} -1 \\ 0 \end{bmatrix}) - \frac{1}{2} \ln 2\pi - \frac{1}{2} * 1 + \ln(0.5)$$

$$g_1(x) = g_2(x) \Rightarrow$$

$$-\frac{1}{2} (x - \begin{bmatrix} 1 \\ 0 \end{bmatrix})^T \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} (x - \begin{bmatrix} 1 \\ 0 \end{bmatrix}) = -\frac{1}{2} (x - \begin{bmatrix} -1 \\ 0 \end{bmatrix})^T \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} (x - \begin{bmatrix} -1 \\ 0 \end{bmatrix})$$

~~$$(x_1 - 1)^2 + (x_2 - 0)^2 = (x_1 + 1)^2 + (x_2 - 0)^2$$~~

$$(x_1 - 1)^2 + (x_2 - 0)^2 = (x_1 + 1)^2 + (x_2 - 0)^2$$

$$\rightarrow x_1^2 - 2x_1 + 1 = x_1^2 + 2x_1 + 1$$

$$\rightarrow \boxed{x_1 = 0} \rightarrow x = \begin{bmatrix} 0 \\ x_2 \end{bmatrix}$$

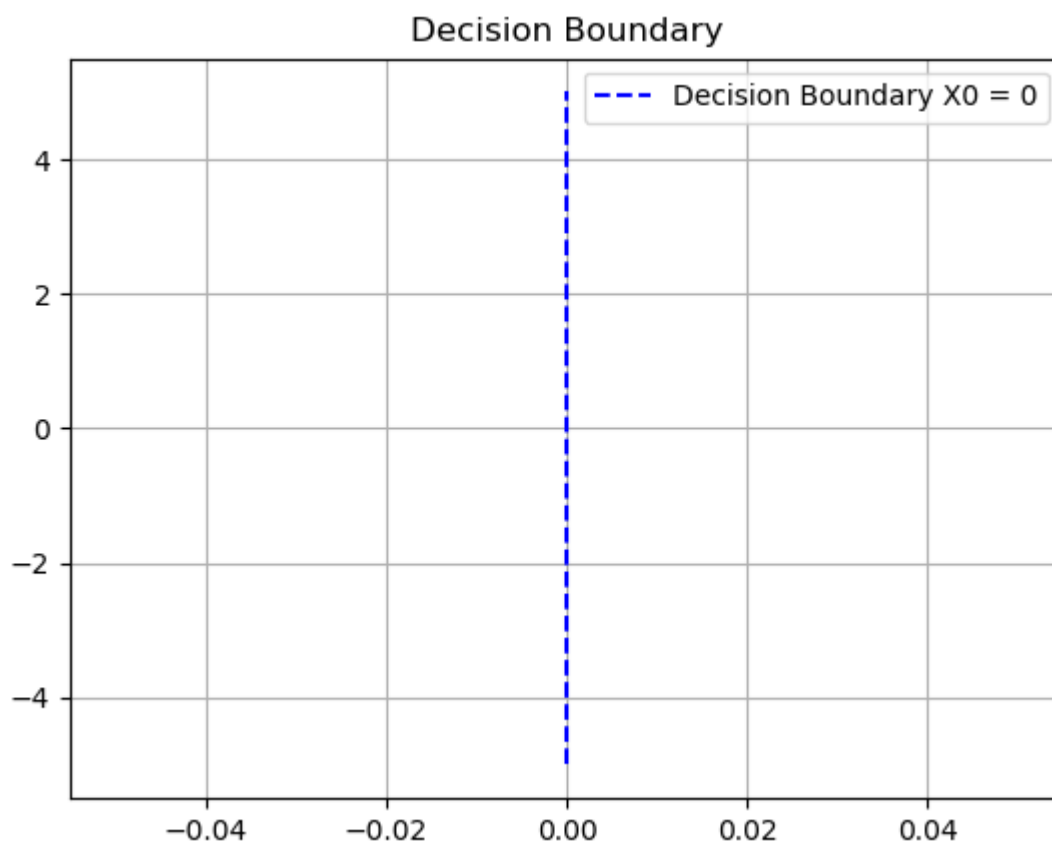
برای رسم مرز تصمیم کد زیر را نوشته ام:

```

28 #####
29 # Computer exercise 7-b
30 #####
31
32 # Distributions of classes
33 xw1 = {'means': [1, 0], 'covariance': [[1, 0], [0, 1]], 'prior': 0.5, 'name': 'w1'}
34 xw2 = {'means': [-1, 0], 'covariance': [[1, 0], [0, 1]], 'prior': 0.5, 'name': 'w2'}
35
36 # As I mathematically have shown in report, decision boundary is  $x_0 = 0$ .
37 # Plot decision boundary
38 y = np.linspace(-5, 5, 100)
39 plt.plot([0]*100, y, 'b--', label='Decision Boundary  $X_0 = 0$ ')
40 plt.title("Decision Boundary")
41 plt.grid()
42 plt.legend()
43 plt.show()
44

```

خروجی اجرای کد بالا را در تصویر زیر مشاهده می‌کنید:



در این بخش به ازای تعداد داده‌های 100، 200، 300، ... و 1000 از هر دو توزیع نرمال داده تولید می‌کنیم و با استفاده از مرز تصمیم گیر آن‌ها را برچسب می‌دهیم و میزان خطا را اندازه می‌گیریم و در نهایت خطاها را رو نمودار هم با باند Bhttacharyya Bound نشان می‌دهیم.

به همین منظور کد زیر را نوشته ام (تابع Bhttacharyya را در تمرین های قبل توضیح داده ام):

```

46 #####
47 # Computer exercise 7- c, d
48 #####
49 def bhttacharyya_bound(normalDist1, normalDist2):
50     """
51     This measure shows similarities between two
52     distribution.
53     :param normalDist1: is dictionary that contains
54     | these keys {'means', 'covariance', 'name', 'prior'}
55     :param normalDist2: is dictionary that contains
56     | these keys {'means', 'covariance', 'name', 'prior'}
57     :return: return a scalar
58     """
59     import numpy as np
60
61     # Convert data to proper form
62     mean1 = np.asmatrix(normalDist1['means'])
63     mean2 = np.asmatrix(normalDist2['means'])
64     cov1 = np.asmatrix(normalDist1['covariance'])
65     cov2 = np.asmatrix(normalDist2['covariance'])
66
67     # Average of two covariances
68     covAve = (cov1 + cov2) / 2
69
70     # Subtract of means

```



```

71     meanSub = mean2 - mean1
72
73     # Calculate the bound
74     bound = (np.sqrt(normalDist1['prior'] * normalDist2['prior'])) * (
75         np.exp(-1 * ((1/8) * (meanSub * np.linalg.inv(covAve) * np.transpose(meanSub)) +
76             (1/2) * np.log(
77                 np.linalg.det(covAve)/np.sqrt(np.linalg.det(cov1) *
78                     np.linalg.det(cov2))
79             ))))
80     #return bound
81     return bound.tolist()[0][0]
82
83
84     # Print Bhattacharyya bound
85     bhb = bhattacharyya_bound(xw1, xw2)
86     print('Bhattacharyya bound for w1 & w2:{}'.format(bhb))
87
88     # For plotting Errors by increasing number of samples
89     errors = []
90
91     # Generate samples for both distribution and classify them
92     # and calculate empirical error of them
93     # Do it for different number of samples 100, 200, 300, ..., 1000
94     startNumOfSamples = 50

```

```

94     startNumOfSamples = 50
95     endNumOfSamples = 501
96     stepOfSample = 50
97     for numOfSamples in np.arange(startNumOfSamples, endNumOfSamples, stepOfSample):
98         # Draw samples from distribution 1
99         w1 = d_normal_distribution(mu=xw1['means'], covMat=xw1['covariance'],
100             n=numOfSamples)
101
102         # Draw samples from distribution 2
103         w2 = d_normal_distribution(mu=xw2['means'], covMat=xw2['covariance'],
104             n=numOfSamples)
105
106         error = 0
107         for samples in w1:
108             # Decision Boundary:  $x_0 = 0$ 
109             if(samples[0] < 0):
110                 error += 1
111
112         for samples in w2:
113             # Decision Boundary:  $x_0 = 0$ 
114             if (samples[0] > 0):
115                 error += 1
116
117         print("Number of sample {}, Error is {}".format(numOfSamples*2, round(error/(len(w1)+len(w2)),3)))

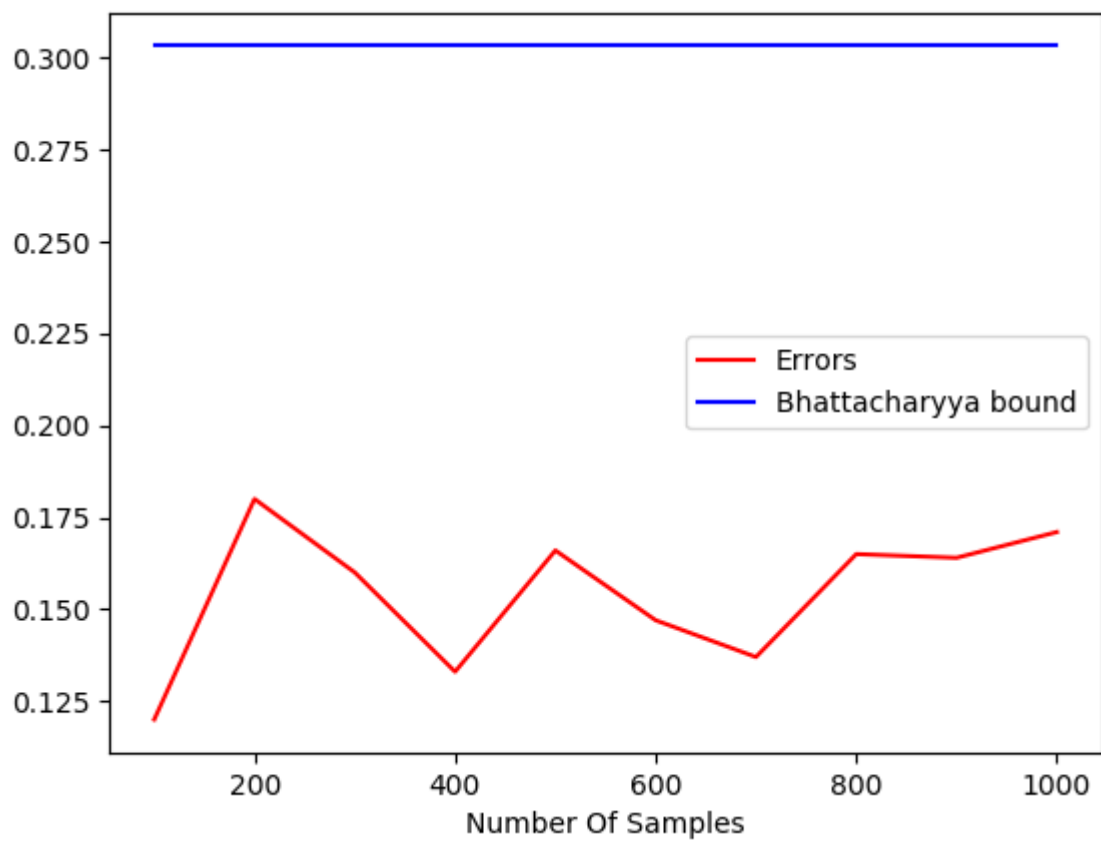
```

```

118
119     # Add error to the list of error
120     errors.append(round(error/(len(w1)+len(w2)),3))
121
122     plt.plot(np.arange(startNumOfSamples*2,
123         endNumOfSamples*2-1,
124         stepOfSample*2).tolist(), errors, 'r-', label="Errors")
125
126     plt.plot(np.arange(startNumOfSamples*2,
127         endNumOfSamples*2-1,
128         stepOfSample*2).tolist(), [bhb]*len(errors), 'b-', label="Bhattacharyya bound")
129     plt.legend()
130     plt.xlabel("Number Of Samples")
131     plt.show()

```

بعد از اجرای کد بالا تصویر خروجی زیر ایجاد می شود:



همین طور که مشاهده می شود مقدار خطا از باند خطا کمتر است و از آن بیشتر نمی شود.